

댓글 관리 서비스 개발 로드맵

현재 집중 단계

1. 댓글 분류 기준 확정

☑ 안전 / 주의 / 위험 사용자 페르소나 설정

▼ 1차 핵심 페르소나

악플을 피하고 싶지만 피드백은 놓치고 싶지 않은 성장기 1인 크리에이터

- 유튜브를 본업 또는 준본업으로 운영한다.
- 댓글 관리 담당자나 매니저가 없다.
- 콘텐츠 개선을 위해 댓글을 직접 확인해야 한다.
- 인신공격이나 조롱 댓글을 읽으면 촬영·편집 의욕이 크게 떨어진다.
- 댓글을 아예 끄면 시청자의 요구와 콘텐츠 아이디어를 놓칠까 봐 걱정한다.
- 거친 표현 속에 실제 피드백이 있다면, 표현은 제거하고 내용만 받고 싶어 한다.
- 모든 댓글을 직접 읽기보다 중요한 의견과 질문만 요약해서 확인하고 싶어 한다.

이 페르소나의 핵심 욕구는 단순히 **"악플 삭제"**가 아니다.

| **상처받지 않으면서도 시청자의 반응을 이용해 콘텐츠를 개선하고 싶다.**

이 문장이 서비스의 중심이 되어야 한다.

페르소나: 성장기 유튜버 지민

- 구독자: 5,000~10만 명
- 업로드 빈도: 주 1~3회
- 운영 형태: 기획·촬영·편집·댓글 관리를 대부분 혼자 수행
- 댓글 수: 영상당 수십~수천 개
- 현재 행동: 업로드 직후 댓글을 반복해서 확인함
- 문제: 긍정 댓글보다 악성 댓글 하나를 오래 기억함
- 갈등: 댓글을 끄고 싶지만, 영상 주제와 개선점을 찾기 위해 계속 확인함
- 현재 해결 방식: 댓글을 안 보려고 하거나 지인에게 먼저 확인해달라고 요청함
- 원하는 결과: 원문은 보지 않고, 개선 의견·질문·시청자 반응만 정리해서 받음

▼ 안전 / 주의 / 위험 댓글 분류 기준 v0.1

목적: 악성 댓글에 취약한 크리에이터가 공격적인 원문을 직접 읽지 않으면서도, 콘텐츠 개선에 필요한 피드백과 질문을 확인할 수 있도록 댓글의 노출 방식을 결정한다.

핵심 원칙: 댓글 작성자의 선악이나 법적 위법성을 판단하는 것이 아니라, 크리에이터에게 원문을 어떻게 보여줄지 판단한다.

▼ 1. 분류 기준 한눈에 보기

● 안전

원문을 그대로 보여줘도 되는 댓글

- 공격적 표현이 없다.
- 콘텐츠나 수정 가능한 행동을 대상으로 한다.
- 일반적인 의견, 질문, 요청, 비판에 해당한다.
- 크리에이터가 원문을 읽어도 정서적 피해가 크지 않다.

처리 방식

- 원문 표시
- 피드백·질문·긍정 반응 등으로 추가 분류
- 주요 의견 요약에 포함

● 주의

원문은 숨기고, 유용한 의미만 순화해서 전달할 댓글

- 욕설, 비속어, 비꼼, 조롱이 포함되어 있다.
- 표현은 공격적이지만 콘텐츠와 관련된 의견이 있다.
- 심각한 인격 공격, 협박, 성희롱, 스토킹은 없다.
- 공격적 표현을 제거하면 실행 가능한 피드백을 추출할 수 있다.

처리 방식

- 원문 기본 숨김
- 욕설과 조롱 제거
- 실행 가능한 피드백만 중립적으로 재작성
- 의미 없는 비난은 개별 전달하지 않고 통계로만 집계

● 위험

원문과 공격의 존재를 기본적으로 노출하지 않을 댓글

- 크리에이터의 인격이나 존재 자체를 공격한다.
- 외모, 신체, 가족, 사생활, 정체성을 공격한다.
- 성희롱, 혐오 표현, 협박, 스토킹이 포함되어 있다.
- 죽음이나 자해를 유도한다.
- 개인정보나 실제 위치를 노출한다.
- 실제 콘텐츠와 관계없는 심각한 개인 공격이다.

처리 방식

- 원문 기본 숨김
- 일반 댓글 요약에서 제외
- 삭제·차단·신고 검토
- 원문과 작성자 정보를 증거용으로 별도 보관
- 협박·스토킹·개인정보 노출은 즉시 알림

▼ 2. 안전 댓글 기준

정의

크리에이터가 댓글 원문을 직접 읽어도 정서적 피해가 크지 않은 댓글이다.

비판적인 내용이라도 콘텐츠, 편집, 음향, 설명 방식처럼 **수정 가능한 대상을 구체적으로 지적한다면 안전**으로 분류한다.

포함 기준

- 욕설이나 조롱이 없다.
- 크리에이터의 인격을 공격하지 않는다.
- 콘텐츠나 행동에 관한 의견이다.
- 일반적인 취향과 부정적 감상을 표현한다.
- 질문이나 요청이 포함되어 있다.
- 구체적인 개선 의견이 있다.

예시

- 영상이 조금 길어서 중간에 집중력이 떨어졌어요.
- 편집 템포를 조금 더 빠르게 해주세요.
- 마이크 소리가 작게 들립니다.

- 이번 영상은 제 취향은 아니었습니다.
- 이 주제로 후속 영상을 만들어주실 수 있나요?
- 설명이 조금 어려웠습니다. 예시를 추가하면 좋을 것 같아요.
- 이전 영상이 더 재미있었어요.
- 재미없다.
- 오늘 얼굴이 피곤해 보여요.

▼ 3. 주의 댓글 기준

정의

욕설, 비꼼, 조롱처럼 공격적인 표현이 포함되어 원문 노출은 적절하지 않지만, 심각한 개인 공격이나 위협까지는 아닌 댓글이다.

댓글 안에 콘텐츠 개선에 사용할 정보가 있다면 **표현을 제거하고 내용만 전달한다.**

포함 기준

- 가벼운 욕설이나 비속어가 포함되어 있다.
- 비꼬거나 무시하는 말투를 사용한다.
- 콘텐츠나 제작 능력을 거칠게 비판한다.
- 공격적인 표현 안에 수정 가능한 의견이 있다.
- 직접적인 인격 공격, 협박, 성희롱, 스토킹은 없다.

자연스러운 말투와 문장부호 사용 기준

순화된 댓글은 모든 문장을 **~요.**로 동일하게 끝내지 않는다.

실제 시청자가 작성한 것처럼 문장의 분위기에 따라 말끝, 문장부호, 이모티콘을 자연스럽게 변화시킨다.

사용할 수 있는 표현

- ~하면 더 좋을 것 같아요.
- ~하면 더 재밌을 것 같아요!
- 다음에는 ~도 보고 싶어요 :)
- ~부분은 조금 아쉬웠어요..
- ~해주시면 더 보기 편할 것 같아요!
- ~도 한 번 해주시면 좋겠어요 ㅎㅎ
- ~해주시면 좋을 것 같아요 ^^
- 다음 영상에서는 ~도 기대할게요!

문장부호 및 이모티콘

사용 가능한 표현:

- .
- !
- ..
- :)
- ^^
- ㅎㅎ

사용 원칙

- 모든 댓글에 이모티콘을 넣지 않는다.
- 한 문장에는 문장부호나 이모티콘을 최대 한 종류만 사용한다.
- 같은 이모티콘을 반복해서 사용하지 않는다.
- 긍정적인 제안이나 요청에는 !, :) , ^^ , ㅎㅎ 를 사용할 수 있다.
- 아쉬움을 표현하는 문장에는 .. 를 제한적으로 사용할 수 있다.
- 심각하거나 민감한 내용에는 이모티콘을 사용하지 않는다.
- 원문에 없는 친밀감이나 과도한 긍정 감정을 추가하지 않는다.
- 😄, ❤️, ㅋㅋㅋㅋ, ㅋㅋ 처럼 감정이 강한 표현은 기본적으로 사용하지 않는다.
- 자연스럽게 않다면 이모티콘 없이 작성한다.

권장 사용 비율

- 일반적인 문장: 약 50%
- !, .. 등 문장부호 변화: 약 30%
- :) , ^^ , ㅎㅎ 등 가벼운 표현: 약 20%

비율은 절대적인 규칙이 아니라, 모든 순화 댓글이 같은 말투로 보이지 않게 하기 위한 기준이다.

순화 예시

원문

| 편집 개느리네.

순화된 댓글 예시

| 편집 템포가 조금 더 빠르면 더 재밌을 것 같아요!

또는

| 편집을 조금만 빠르게 해주시면 좋을 것 같아요 :)

원문

| 말 너무 답답하게 한다.

순화된 댓글 예시

| 설명을 조금 더 빠르고 간결하게 해주시면 좋을 것 같아요.

또는

| 말하는 속도가 조금 더 빠르면 보기 편할 것 같아요!

원문

| 또 똑같은 콘텐츠네. 진짜 질린다.

순화된 댓글 예시

| 다음에는 새로운 콘텐츠도 보고 싶어요 :)

또는

| 다른 형식의 콘텐츠도 한 번 보고 싶어요!

원문

| 썸네일 낚시 좀 그만해라.

순화된 댓글 예시

| 썸네일과 영상 내용이 조금 더 잘 맞으면 좋을 것 같아요..

또는

| 썸네일에서 영상 내용을 조금 더 정확하게 보여주시면 좋겠어요.

원문

| 영상이 왜 이렇게 쓸데없이 길어.

순화된 댓글 예시

| 영상 길이가 조금 짧으면 더 집중해서 볼 수 있을 것 같아요!

또는

| 핵심 내용 위주로 조금만 줄여주시면 더 보기 좋을 것 같아요 :)

원문

| 자막 크기 실화냐? 눈 빠지겠다.

순화된 댓글 예시

| 자막을 조금 더 크게 해주시면 보기 편할 것 같아요!

또는

| 자막 크기가 조금만 더 크면 좋겠어요 ^^

원문

| 맨날 같은 말만 반복하네.

순화된 댓글 예시

| 반복되는 설명을 조금 줄이면 영상이 더 깔끔할 것 같아요.

또는

| 설명이 조금 더 간결하면 더 집중해서 볼 수 있을 것 같아요!

부자연스러운 예시

이모티콘을 과도하게 사용하지 않는다

부적절한 예시:

| 편집을 조금 더 빠르게 해주시면 정말 좋을 것 같아요!! ^^ :)

권장 예시:

| 편집 템포가 조금 더 빠르면 재밌을 것 같아요!

원문에 없는 호감을 만들지 않는다

원문

| 또 똑같은 콘텐츠네.

부적절한 예시:

| 항상 영상 너무 잘 보고 있어요! 다음에는 새로운 콘텐츠도 부탁드립니다 :)

권장 예시:

| 다음에는 새로운 콘텐츠도 보고 싶어요 :)

원문에 **항상 잘 보고 있다** 는 내용이 없으므로 임의로 추가하지 않는다.

심각한 의견을 장난스럽게 바꾸지 않는다

원문

목소리가 너무 작아서 무슨 말인지 하나도 모르겠다.

부적절한 예시:

목소리 좀 키워주세요 ㅎㅎ

권장 예시:

목소리 음량을 조금 높여주시면 더 잘 들릴 것 같아요.

ㅎㅎ 를 붙이면 불편의 강도가 지나치게 가볍게 변할 수 있다.

AI 순화 지침

댓글의 욕설, 비꼼, 조롱, 공격적인 표현을 제거하고, 실제 시청자가 크리에이터에게 직접 예의 있게 작성한 것처럼 자연스러운 한국어 댓글로 다시 작성한다. 원문의 핵심 피드백은 유지하되 원문에 없는 칭찬, 호감, 구체적인 해결책은 추가하지 않는다. 모든 문장을 동일한 말투로 작성하지 말고, 문맥에 따라 **. , ! , .. , :) , ^^ , ㅎㅎ** 중 하나를 제한적으로 사용할 수 있다. 이모티콘이나 특수한 문장부호는 자연스러운 경우에만 사용하고, 한 문장에 하나를 초과하지 않는다. 민감하거나 심각한 내용에는 이모티콘을 사용하지 않는다. 구체적인 개선 정보가 없다면 순화된 댓글을 생성하지 않는다.

AI 출력 예시

```
{
  "risk_level": "caution",
  "feedback_present": true,
  "rewritten_comment": "편집 템포가 조금 더 빠르면 재밌을 것 같아요!",
  "tone_variant": "friendly",
  "reason_codes": ["profanity", "harsh_expression"],
  "recommended_action": "show_rewritten_comment"
}
```

tone_variant 는 다음 세 가지 정도로 두는 것이 좋다.

- **neutral** : 차분하고 일반적인 말투
- **friendly** : **! , :) , ^^** 등을 가볍게 사용
- **soft_disappointment** : 아쉬움을 부드럽게 표현하는 말투

핵심은 랜덤으로 이모티콘을 붙이는 것이 아니라, 원문의 내용과 감정에 맞는 자연스러운 시청자 말투를 선택하는 것이다.

▼ 4. 위험 댓글 기준

정의

크리에이터 개인의 인격, 외모, 가족, 사생활, 정체성 또는 안전을 공격하는 댓글이다.
실제 피해로 이어질 수 있는 협박, 성희롱, 스토킹, 개인정보 노출도 위험에 포함한다.

포함 기준

다음 중 하나라도 포함되면 위험으로 우선 분류한다.

- 인격이나 존재 자체에 대한 공격
- 외모·신체에 대한 모욕
- 가족이나 지인에 대한 공격
- 성적인 대상화 또는 성희롱
- 죽음이나 자해 유도
- 직접적이거나 암시적인 협박
- 주소·전화번호·실제 위치 등 개인정보 노출
- 지속적인 스토킹 또는 반복 괴롭힘
- 정체성을 대상으로 한 혐오 표현
- 콘텐츠와 관계없는 심각한 개인 공격

예시

- 못생긴 게 왜 자꾸 얼굴을 보여주냐.
- 너 같은 인간은 유튜브 하면 안 된다.
- 그냥 죽어라.
- 어디 사는지 알고 있다.
- 다음에 직접 찾아간다.
- 가족들도 똑같이 문제 있는 것 같다.
- 신체를 대상으로 한 성적인 댓글
- 실제 주소나 위치가 포함된 댓글
- 여러 영상에 반복해서 작성하는 집착성 댓글
- 넌 머리가 나빠서 설명도 못한다.

피드백이 함께 있는 위험 댓글

원문

| 넌 진짜 멍청한 것 같고 설명도 너무 길다.

분류

- 위험도: 위험
- 원문 노출: 숨김
- 피드백 존재: 있음
- 추출 내용: 설명을 더 간결하게 해달라는 의견

위험 댓글에 피드백이 포함되어 있어도 **위험 등급은 낮추지 않는다.**

▼ 5. 분류 우선순위

댓글에 여러 요소가 함께 있으면 가장 높은 위험도를 적용한다.

위험 요소가 있으면 위험

위험은 없지만 공격적 표현이 있으면 주의

공격적 표현이 없으면 안전

판단 순서

- 위험 판단 → 주의 판단 → 안전 판단

1. 협박·스토킹·성희롱·자해 유도·개인정보 노출이 있는가?

- 있다면 **위험**

2. 인격·외모·가족·사생활·정체성을 공격하는가?

- 그렇다면 **위험**

3. 욕설·비꼼·조롱이 포함되어 있는가?

- 그렇다면 **주의**

4. 공격적 표현 없이 콘텐츠에 대한 의견을 제시하는가?

- 그렇다면 **안전**

경계 사례

댓글	분류	판단 이유
재미없다	안전	일반적인 콘텐츠 감상
개노잼	주의	비속어가 포함된 부정 반응
설명이 이해하기 어렵다	안전	구체적인 콘텐츠 피드백
설명을 왜 이렇게 못하냐	주의	공격적인 콘텐츠 비판
넌 머리가 나빠서 설명도 못한다	위험	개인의 능력과 인격 공격
오늘 얼굴이 피곤해 보여요	안전	공격 의도가 없는 관찰
그 얼굴로 방송을 왜 하냐	위험	외모를 이용한 개인 공격
영상 좀 짧게 만들어주세요	안전	구체적인 요청

댓글	분류	판단 이유
이판 걸 20분이나 만들었냐	주의	조롱이 포함된 콘텐츠 비판

▼ 6. AI가 반환해야 하는 결과

안전 / 주의 / 위험 등급과 피드백 여부를 별도로 판단한다.

필수 반환 항목

- 위험도: 안전 / 주의 / 위험
- 피드백 존재: 있음 / 없음
- 순화된 피드백
- 분류 사유
- 권장 처리 방식

분류 사유 코드

- 욕설
- 비속어
- 조롱
- 비꼼
- 개인 공격
- 외모 공격
- 가족 공격
- 성희롱
- 혐오 표현
- 협박
- 스토킹
- 개인정보 노출
- 자해·죽음 유도

권장 처리 방식

- 원문 표시
- 순화된 내용만 표시
- 원문 숨김
- 삭제 검토
- 차단 검토

- 신고 검토
- 증거 보관
- 즉시 알림

반환 예시

```
{
  "risk_level": "caution",
  "feedback_present": true,
  "sanitized_feedback": "영상의 편집 템포를 더 빠르게 해달라는 의견이 있습니다.",
  "reason_codes": ["profanity", "mockery"],
  "recommended_action": "show_sanitized_only"
}
```

▼ 7. 분류 기준 확정 절차

1단계: 기준 데이터 준비

- ☐ 안전 댓글 30개
- ☐ 주의 댓글 30개
- ☐ 위험 댓글 30개
- ☐ 경계 사례 10개

총 100개의 기준 댓글을 준비한다.

2단계: 사람 기준 분류

- ☐ 팀원이 서로 상의하지 않고 같은 댓글을 각각 분류한다.
- ☐ 결과가 다른 댓글을 따로 모은다.
- ☐ 의견이 갈린 이유를 기록한다.
- ☐ 기준 문장을 수정한다.

3단계: 기준 확정

- ☐ 사람 간 분류 일치율 85% 이상 달성
- ☐ 의견이 갈린 댓글을 경계 사례에 추가
- ☐ 최종 정답 데이터셋 확정
- ☐ 댓글 분류 기준 v1.0으로 업데이트

4단계: AI 테스트

- ☐ 같은 댓글을 여러 번 분류해 결과 일관성 확인
- ☐ 사람의 정답과 AI 결과 비교

- ☐ 안전을 주의·위험으로 잘못 판단한 사례 확인
- ☐ 위험을 안전·주의로 놓친 사례 우선 수정
- ☐ 프롬프트 변경 전후 결과 비교

최종 분류 원칙

콘텐츠에 대한 일반적인 의견은 안전, 공격적인 표현이 섞인 콘텐츠 비판은 주의, 크리에이터 개인의 인격·외모·사생활·정체성·안전을 공격하면 위험으로 분류한다.

▼ 8. 댓글 분류 가이드라인 v0.1

목표: 안전 댓글은 빠르고 저렴하게 처리하고, 주의·위험 댓글은 한 번 더 검증하여 악성 댓글이 사용자에게 직접 노출되는 것을 최소화한다.

기본 원칙: 사용자 맞춤 기준은 반영하되, 협박·스토킹·성희롱·개인정보 노출 등 명확한 위험 요소는 사용자의 설정으로 완화하지 않는다.

▼ 전체 분류 흐름

```

댓글 입력
↓
1차 분류
├─ 확실한 안전 → 원문 표시
└─ 주의·위험·의심스러운 안전 → 2차 검증
↓
최종 등급 확정
├─ 안전 → 원문 표시
├─ 주의 → 피드백 순화
└─ 위험 → 숨김·보관·신고 검토
  
```

▼ 0. 사용자별 분류 프로필 준비

사용자의 성향을 매번 자유로운 문장으로 전달하지 않고, **구조화된 분류 프로필**로 저장한다.

사용자별 저장 항목

- 민감하게 느끼는 공격 대상
- 허용 가능한 욕설·비속어 수준
- 채널에서 자주 사용하는 은어
- 팬들 사이에서 허용되는 장난과 밈

- 반드시 위험으로 처리할 주제
- 원문 노출 허용 수준
- 순화된 댓글의 선호 말투
- 사용자가 직접 분류한 대표 댓글 예시

예시

```
{
  "protection_level": "high",
  "allowed_slang": ["개웃기다", "미쳤다"],
  "sensitive_topics": ["외모", "가족", "학력"],
  "hide_personal_attacks": true,
  "rewrite_tone": "friendly",
  "emoji_frequency": "medium"
}
```

적용 원칙

- 사용자 프로필은 안전과 주의의 경계 조정에 사용한다.
- 협박, 개인정보 노출, 스토킹, 성희롱 등은 사용자 설정과 관계없이 위험으로 처리한다.
- 사용자별 과거 분류 사례 중 현재 댓글과 유사한 예시만 RAG로 가져온다.
- RAG 검색 결과만으로 최종 등급을 결정하지 않는다.
- 사용자 프로필과 분류 기준에는 버전을 부여한다.

▼ 1. 1차 분류

모든 댓글은 한 번의 AI 호출로 먼저 분석한다.

입력 정보

- 댓글 원문
- 댓글이 작성된 영상 정보
- 전체 공통 분류 기준
- 사용자별 분류 프로필
- RAG로 검색한 유사 분류 예시
- 필요한 경우 댓글 작성자의 반복 행동 정보

판단 항목

- 안전 / 주의 / 위험 예상 등급
- 개인 공격 여부
- 외모·가족·사생활 공격 여부

- 욕설·비꼼·조롱 여부
- 협박·스토킹·성희롱 여부
- 개인정보 노출 여부
- 콘텐츠 피드백 존재 여부
- 핵심 피드백 내용
- 판단 확신도
- 2차 검증 필요 여부

반환 예시

```
{
  "candidate_level": "caution",
  "hard_risk_flags": [],
  "soft_risk_flags": ["profanity", "harsh_expression"],
  "feedback_present": true,
  "feedback_core": "편집 템포가 느리다",
  "confidence": 0.91,
  "matched_user_rules": ["high_protection_level"],
  "requires_second_pass": true
}
```

1차 분류 통과 기준

다음 조건을 모두 만족하는 댓글만 바로 안전으로 확정한다.

- 예상 등급이 안전이다.
- 확신도가 기준 이상이다.
- 욕설·조롱·개인 공격 플래그가 없다.
- 협박·스토킹·개인정보 관련 단어나 패턴이 없다.
- 사용자별 민감 주제와 충돌하지 않는다.
- 반복 괴롭힘이 의심되지 않는다.

| **확실한 안전 댓글만 1차에서 종료하고, 조금이라도 애매하면 2차 검증으로 보낸다.**

▼ 2. 2차 검증

모든 댓글을 다시 판단하지 않고, 다음 댓글만 2차 검증한다.

2차 검증 대상

- 1차에서 주의로 분류된 댓글
- 1차에서 위험으로 분류된 댓글
- 확신도가 낮은 안전 댓글
- 위험 관련 키워드나 패턴이 감지된 안전 댓글

- 사용자별 민감 주제와 충돌한 댓글
- RAG 예시와 1차 판단이 충돌한 댓글
- 동일 작성자의 반복 괴롭힘이 의심되는 댓글
- 여러 의미로 해석할 수 있는 댓글

2차 검증 목적

- 주의와 위험의 경계를 다시 판단한다.
- 위험 댓글이 안전이나 주의로 내려가는 오류를 줄인다.
- 채널 내부 밈이나 친근한 장난을 악성 댓글로 오해했는지 확인한다.
- 피드백이 실제로 존재하는지 다시 확인한다.
- 순화 가능한 댓글인지 판단한다.

2차 검증 방식

1차 결과를 그대로 승인하지 않고, **별도의 검증 프롬프트**로 다시 판단한다.

가능하면 1차와 다음 요소 중 하나 이상을 다르게 한다.

- 분류 프롬프트
- 제공하는 예시
- 판단 역할
- 사용하는 모델
- temperature 설정

최종 등급 확정 규칙

- 1차와 2차 결과가 같으면 해당 등급으로 확정한다.
- 안전과 주의가 충돌하면 사용자 화면에서는 주의로 처리한다.
- 주의와 위험이 충돌하면 사용자 화면에서는 위험으로 처리한다.
- 명확한 위험 요소가 확인되면 무조건 위험으로 처리한다.
- 판단이 계속 애매하면 원문을 노출하지 않고 검토 대상으로 보낸다.

두 판단 일치 → 해당 등급 확정

두 판단 불일치 → 더 높은 보호 등급 적용

협박·스토킹·개인정보·성희롱 확인 → 위험 확정

▼ 3. 최종 등급별 처리

처리

● 안전

- 원문을 그대로 표시한다.
- 피드백, 질문, 긍정 반응 등으로 추가 분류한다.
- 별도의 순화 작업은 진행하지 않는다.

● 주의 + 피드백 있음

- 원문을 사용자에게 기본적으로 숨긴다.
- 핵심 피드백만 추출한다.
- 별도의 순화 모델을 호출한다.
- 실제 시청자가 예의 있게 작성한 것처럼 다시 작성한다.
- 원문에 없는 칭찬이나 해결책은 추가하지 않는다.

● 주의 + 피드백 없음

- 순화된 댓글을 만들지 않는다.
- 원문은 숨긴다.
- 개별 댓글로 전달하지 않는다.
- 부정 반응 통계에만 포함한다.

● 위험

- 원문을 사용자에게 기본적으로 노출하지 않는다.
- 순화된 댓글도 생성하지 않는다.
- 삭제·차단·신고 검토 대상으로 분류한다.
- 원문과 작성자 정보를 증거용으로 보관한다.
- 협박·스토킹·개인정보 노출은 즉시 알림 대상으로 처리한다.

위험 댓글에 일부 피드백이 포함되어 있어도 MVP에서는 개별 순화 댓글로 전달하지 않는다. 여러 위험 댓글에서 동일한 피드백이 반복되는 경우에만 익명화된 종합 의견으로 검토한다.

▼ 4. 주의 댓글 순화

순화 작업은 **최종 등급이 주의이고, 실행 가능한 피드백이 있는 댓글에만 실행한다.**

순화 입력

- 댓글 원문
- 추출된 핵심 피드백
- 사용자 선호 말투
- 이모티콘 사용 빈도

- 최근 생성된 순화 댓글의 문체

순화 원칙

- 욕설, 비꼼, 조롱을 제거한다.
- 원문의 핵심 피드백은 유지한다.
- 시청자가 직접 작성한 것처럼 자연스럽게 쓴다.
- 원문에 없는 칭찬이나 호감은 추가하지 않는다.
- ~라는 의견이 있습니다 같은 보고형 표현은 사용하지 않는다.
- 최근 생성된 문장과 종결 표현이 반복되지 않게 한다.
- 문맥에 따라 . , ! , .. , :) , ^^ , ㅎㅎ 를 제한적으로 사용한다.

출력 예시

원문

| 편집 개느리네.

순화된 댓글

| 편집 템포가 조금 더 빠르면 더 재밌을 것 같아요!


원문

| 또 똑같은 콘텐츠네. 진짜 질린다.

순화된 댓글

| 다음에는 새로운 콘텐츠도 보고 싶어요 :)

▼ 5. 추천 최종 구조



이 구조의 장점

- 대부분의 안전 댓글은 AI 호출 한 번으로 종료된다.
- 주의·위험 댓글만 추가 비용이 발생한다.

- 위험 댓글이 안전으로 잘못 노출되는 가능성을 낮춘다.
- 사용자별 분류 성향을 반영할 수 있다.
- 분류와 순화를 분리해 각각 따로 개선할 수 있다.
- 분류 오류가 발생했을 때 원인을 추적하기 쉽다.

▼ 6. 비용 구조

확실한 안전 댓글

- 1차 분류 1회
- 순화 호출 없음

주의 댓글

- 1차 분류 1회
- 2차 검증 1회
- 피드백이 있는 경우 순화 1회

위험 댓글

- 1차 분류 1회
- 2차 검증 1회
- 순화 호출 없음

따라서 모든 댓글을 세 번 처리하는 구조가 아니다.

└ 안전 댓글 대부분은 1회, 위험 댓글은 2회, 순화가 필요한 주의 댓글만 최대 3회 처리한다.

▼ 7. RAG 적용 시 주의점

RAG에 저장할 것

- 사용자가 직접 수정한 분류 결과
- 사용자가 안전으로 허용한 댓글
- 사용자가 주의 또는 위험으로 변경한 댓글
- 채널에서 자주 사용하는 은어와 밈
- 특정 공격 대상에 대한 민감도
- 순화 문체 선호 예시

RAG에 의존하지 않을 것

- 협박 판단
- 개인정보 노출 판단

- 스톡킹 판단
- 성희롱 판단
- 자해·죽음 유도 판단
- 명확한 혐오 표현 판단

이 항목들은 사용자별 RAG보다 전체 공통 위험 기준을 우선한다.

권장 방식

고정된 공통 기준 + 구조화된 사용자 프로필 + 유사 사례 RAG

RAG만으로 사용자를 파악하거나, 과거 댓글 전체를 매번 프롬프트에 넣는 방식은 사용하지 않는다.

▼ 8. 테스트 시 우선 확인할 지표

1. 위험 댓글을 안전으로 잘못 분류한 비율
2. 위험 댓글을 주의로 잘못 분류한 비율
3. 안전 댓글을 불필요하게 주의·위험으로 분류한 비율
4. 1차와 2차 판단이 충돌하는 비율
5. 순화 과정에서 원문에 없는 의미가 추가된 비율
6. 사용자 수정 결과가 개인화 기준에 반영되는 정도

가장 중요한 우선순위

위험 → 안전 오분류 최소화
↓
위험 → 주의 오분류 최소화
↓
안전 댓글의 과잉 차단 감소
↓
순화 문장의 자연스러움 개선

▼ 9. MVP 구현 체크리스트

- ☐ 전체 공통 안전 / 주의 / 위험 기준 확정
- ☐ 절대 완화할 수 없는 위험 기준 확정
- ☐ 사용자별 분류 프로필 구조 확정
- ☐ 사용자별 RAG 데이터 형식 확정
- ☐ 1차 분류 프롬프트 작성
- ☐ 1차 분류 JSON 출력 형식 확정
- ☐ 2차 검증 대상 라우팅 규칙 작성
- ☐ 2차 검증 프롬프트 작성

- ☐ 1차·2차 결과 충돌 처리 규칙 작성
- ☐ 주의 댓글 순화 프롬프트 작성
- ☐ 안전 댓글 즉시 통과 로직 구현
- ☐ 위험 댓글 증거 보관 로직 구현
- ☐ 테스트 댓글 데이터셋 구축
- ☐ 분류 정확도와 비용 비교

▼ 최종 결정

1차에서 모든 댓글을 사용자별 기준과 함께 안전·주의·위험으로 분류한다. 확실한 안전 댓글은 바로 통과시키고, 주의·위험 및 의심스러운 안전 댓글만 2차 검증한다. 최종적으로 주의이면서 피드백이 있는 댓글만 자연스러운 시청자 말투로 순화한다. 위험 댓글은 순화하지 않고 숨김·보관·신고 검토 대상으로 처리한다.

☒ 각 등급별 대표 댓글 예시 정리

▼ 대표 댓글 작성 기준

- ☐ 안전 / 주의 / 위험별 대표 댓글을 최소 10개씩 작성한다.
- ☐ 단순한 사례뿐 아니라 등급이 헛갈리는 경계 사례를 포함한다.
- ☐ 댓글마다 분류 이유를 한 문장으로 작성한다.
- ☐ 주의 댓글은 피드백 존재 여부와 순화 결과를 작성한다.
- ☐ 위험 댓글은 위험 유형과 처리 방식을 작성한다.
- ☐ 팀원이 모두 동의한 댓글만 **확정** 상태로 변경한다.
- ☐ 사용자 개인화 사례는 공통 기준과 분리해서 관리한다

▼ ● 안전 대표 댓글

안전 판단 기준

- 욕설·조롱·인신공격이 없다.
- 콘텐츠나 수정 가능한 행동을 대상으로 한다.
- 부정적인 의견이라도 원문을 그대로 보여줘도 된다.
- 일반적인 질문, 요청, 감상, 피드백에 해당한다.

댓글 원문	세부 유형	피드백	분류 이유	처리
영상이 조금 길어서 중간에 집중력이 떨어졌어요.	영상 길이	있음	공격적 표현 없이 영상 길이를 지적함	원문 표시
편집 템포를 조금 더 빠르게 해주세요.	편집	있음	구체적이고 실행 가능한 요청	원문 표시

댓글 원문	세부 유형	피드백	분류 이유	처리
마이크 소리가 작게 들립니다.	음향	있음	수정 가능한 기술적 문제를 전달함	원문 표시
이번 영상은 제 취향은 아니었어요.	일반 감상	없음	개인의 취향을 공격 없이 표현함	원문 표시
이전 영상이 더 재미있었어요.	콘텐츠 비교	있음	콘텐츠에 관한 일반적인 비교 의견	원문 표시
설명이 조금 어려웠습니다.	설명 방식	있음	공격 없이 이해의 어려움을 전달함	원문 표시
다음에는 새로운 주제도 다뤄주세요.	콘텐츠 요청	있음	새로운 콘텐츠를 요청함	원문 표시
재미없다.	일반 감상	없음	거칠지 않은 단순 부정 감상	원문 표시
오늘 얼굴이 피곤해 보여요.	외형 관찰	없음	모욕이나 조롱이 없는 단순 관찰	원문 표시
이 내용의 출처가 궁금해요.	질문	있음	정보 확인을 위한 일반 질문	원문 표시

▼ ● 주의 대표 댓글

주의 판단 기준

- 욕설, 비속어, 비꼼, 조롱이 포함되어 있다.
- 원문을 그대로 노출하기에는 공격적이다.
- 심각한 개인 공격이나 위협은 아니다.
- 공격적 표현을 제거하면 콘텐츠 피드백을 추출할 수 있다.

댓글 원문	세부 유형	피드백	핵심 피드백	순화된 댓글	처리
편집 개느리네.	욕설성 표현	있음	편집 속도가 느림	편집 템포가 조금 더 빠르면 더 재밌을 것 같아요!	순화해서 표시
말 너무 답답하게 한다.	거친 표현	있음	말하는 속도와 전개가 느림	설명을 조금 더 빠르고 간결하게 해주시면 좋을 것 같아요.	순화해서 표시
또 똑같은 콘텐츠네. 진짜 질린다.	비꼼	있음	새로운 콘텐츠를 원함	다음에는 새로운 콘텐츠도 보고 싶어요 :)	순화해서 표시
썸네일 낚시 좀 그만해라.	비난	있음	썸네일과 내용이 다름	썸네일과 영상 내용이 조금 더 잘 맞으면 좋을 것 같아요..	순화해서 표시

댓글 원문	세부 유형	피드백	핵심 피드백	순화된 댓글	처리
영상이 왜 이렇게 쓸데없이 길어.	거친 비판	있음	영상 길이가 김	영상 길이가 조금 짧으면 더 집중해서 볼 수 있을 것 같아요!	순화해서 표시
자막 크기 실화냐? 눈 빠지겠다.	조롱	있음	자막이 작음	자막을 조금 더 크게 해주시면 보기 편할 것 같아요!	순화해서 표시
맨날 같은 말만 반복하네.	비난	있음	설명이 반복됨	반복되는 설명을 조금 줄이면 영상이 더 깔끔할 것 같아요.	순화해서 표시
정보 확인도 안 하고 올리냐?	공격적 질문	있음	정보의 정확성이 부족함	영상에 나온 정보를 한 번 더 확인 해주시면 좋을 것 같아요.	순화해서 표시
개노잰.	비속어	없음	없음	생성하지 않음	부정 반응 통계
이딴 영상은 왜 올리는 거냐.	콘텐츠 비하	없음	없음	생성하지 않음	원문 숨김 및 통계

▼ ● 위험 대표 댓글

위험 판단 기준

- 크리에이터 개인의 인격이나 존재 자체를 공격한다.
- 외모, 신체, 가족, 사생활, 정체성을 공격한다.
- 협박, 스토킹, 성희롱, 개인정보 노출이 포함되어 있다.
- 죽음이나 자해를 유도한다.
- 콘텐츠 피드백보다 공격과 위해 가능성이 중심이다.

댓글 원문	위험 유형	피드백	분류 이유	처리
못생긴 게 왜 자꾸 얼굴을 보여주냐.	외모 공격	없음	콘텐츠가 아닌 외모를 모욕함	숨김·차단 검토
너 같은 인간은 유튜브 하면 안 된다.	인격 공격	없음	사람의 존재와 자격을 공격함	숨김·차단 검토
그냥 죽어라.	죽음 유도	없음	직접적으로 죽음을 유도함	숨김·신고 검토
어디 사는지 알고 있다.	스토킹·위협	없음	실제 위치를 알고 있음을 암시함	즉시 알림·증거 보관
다음에 직접 찾아간다.	위협	없음	실제 접근과 위해 가능성을 암시함	즉시 알림·신고 검토
가족들도 똑같이 문제 있는 것 같다.	가족 공격	없음	크리에이터의 가족을 공격함	숨김·차단 검토

댓글 원문	위험 유형	피드백	분류 이유	처리
넌 머리가 나빠서 설명도 못한다.	능력·인격 공격	있음	피드백보다 개인의 지능을 공격함	숨김
몸매를 대상으로 한 성적인 댓글	성희롱	없음	신체를 성적으로 대상화함	숨김·신고 검토
실제 주소나 전화번호가 포함된 댓글	개인정보 노출	없음	개인의 안전에 직접적인 위험이 있음	즉시 숨김·증거 보관
여러 영상에 반복해서 집착성 댓글을 작성함	반복 괴롭힘	없음	개별 표현보다 반복 행동이 위험함	작성자 차단·증거 보관

▼ ⚖️ 경계 사례

등급이 헛갈릴 가능성이 높은 댓글은 별도로 관리한다.

안전에 가까운 댓글	주의·위험에 가까운 댓글	최종 분류 기준
재미없다.	개노잼.	비속어가 포함되면 주의
설명이 이해하기 어렵다.	설명을 왜 이렇게 못하냐.	공격적 표현이 있으면 주의
설명을 왜 이렇게 못하냐.	넌 머리가 나빠서 설명도 못한다.	개인의 지능·인격을 공격하면 위험
오늘 얼굴이 피곤해 보여요.	그 얼굴로 방송을 왜 하냐.	외모를 모욕에 사용하면 위험
영상이 너무 길어요.	이딴 걸 20분이나 만들었냐.	조롱이나 비하가 포함되면 주의
다음에는 다른 콘텐츠도 보고 싶어요.	맨날 똑같은 것만 올리네.	공격적 말투가 포함되면 주의
정보가 정확한지 궁금해요.	확인도 안 하고 영상 올리냐?	비난형 표현이면 주의
집 근처에서 봤어요.	어디 사는지 알고 있다.	위치 인식이 위협으로 사용되면 위험

▼ 사용자별 대표 댓글

공통 기준과 별도로, 각 사용자의 분류 성향을 보여주는 예시를 저장한다.

저장 항목

- 사용자 ID
- 댓글 원문
- 공통 기준 분류
- 사용자가 원하는 분류
- 변경 이유
- 적용할 사용자 규칙
- RAG 저장 여부

예시

댓글 원문	공통 분류	사용자 분류	변경 이유	적용 규칙
오늘 좀 피곤해 보여요.	안전	주의	외모 관련 언급을 원하지 않음	외모 언급 민감

댓글 원문	공통 분류	사용자 분류	변경 이유	적용 규칙
개웃기다.	주의	안전	채널에서 긍정 표현으로 사용됨	허용 은어
또 게임 못하네ㅋㅋ	주의	안전	팬들 사이의 가벼운 밈	채널 밈
살 좀 빼야겠다.	위험	위험	외모 평가를 전부 차단함	외모 공격 차단

사용자 개인화는 안전과 주의의 경계를 조정할 수 있지만, 협박·스토킹·개인정보 노출 등 명확한 위험 등급은 낮추지 않는다.

▼ 댓글 예시 관리 상태

각 댓글에 다음 상태를 부여한다.

- **초안** : 아직 검토하지 않은 사례
- **논의 필요** : 팀원 간 판단이 다른 사례
- **확정** : 팀이 분류에 합의한 사례
- **수정 필요** : 테스트 결과 기준 변경이 필요한 사례
- **사용자 전용** : 특정 사용자에게만 적용되는 사례

▼ 완료 기준

- ☐ 안전 대표 댓글 10개 이상 확정
- ☐ 주의 대표 댓글 10개 이상 확정
- ☐ 위험 대표 댓글 10개 이상 확정
- ☐ 경계 사례 10개 이상 확정
- ☐ 주의 댓글의 순화 결과 작성
- ☐ 각 댓글의 분류 이유 작성
- ☐ 각 댓글의 예상 처리 방식 작성
- ☐ 팀원 간 분류 일치 여부 확인
- ☐ 테스트 하네스에서 사용할 정답 데이터로 변환

최종 완료 기준: 새로운 댓글이 들어왔을 때, 가장 유사한 대표 사례를 찾아 동일한 기준으로 분류할 수 있는 상태.

완료 기준: 같은 댓글을 여러 번 분류해도 결과가 일관되게 나오는 상태

2. AI 분류 테스트 환경 구축 → 그냥 테스트 API를 사용하는 것이 좋을듯 1차는 5.6 luna로, 2차 주의, 위험 댓글은 5.6 terra로 분류

- ☒ ChatGPT 기반 테스트 하네스 만들기
- ☒ 테스트 댓글 데이터 준비

- ☒ 테스트 실행 방식과 평가 기준 확정
- ☒ 분류 결과 기록 및 비교

완료 기준: 프롬프트나 기준을 변경했을 때 성능 차이를 비교할 수 있는 상태

서비스 테스트 준비

3. 테스트용 유튜브 환경 구축

- ☐ 테스트용 유튜브 계정 및 채널 만들기
- ☐ 테스트 영상 업로드
- ☐ 안전 / 주의 / 위험 댓글 작성
- ☐ 실제 댓글 수집 및 분류 테스트

완료 기준: 유튜브 댓글을 가져와 서비스 전체 흐름을 테스트할 수 있는 상태

출시 준비

4. UI 수정

- ☐ 핵심 화면 사용 흐름 점검
- ☐ 댓글 등급과 분석 결과가 직관적으로 보이도록 수정
- ☐ 테스트 중 발견된 불편 사항 수정

완료 기준: 처음 사용하는 사람도 설명 없이 주요 기능을 사용할 수 있는 상태

5. 배포

- ☐ 운영 환경 배포
- ☐ 로그인 및 유튜브 연동 점검
- ☐ 댓글 수집·분류·결과 표시 점검
- ☐ 오류 확인 및 수정

완료 기준: 외부 사용자가 접속해 서비스를 정상적으로 테스트할 수 있는 상태

사용자 확보

6. 마케팅 준비 및 실행

- ☐ 핵심 고객과 메시지 확정
- ☐ 랜딩페이지 및 서비스 소개 문구 준비
- ☐ 크리에이터 인터뷰 및 테스트 사용자 모집

- ☐ DM·이메일·커뮤니티를 통한 초기 사용자 확보
- ☐ 사용자 반응과 재사용 여부 기록

완료 기준: 실제 크리에이터가 서비스를 사용하고 피드백을 전달하는 상태

전체 진행 순서

- ☐ 1. 분류 페르소나 및 기준 확정
- ☐ 2. 테스트 하네스 구축
- ☐ 3. 테스트용 유튜브 환경 구축
- ☐ 4. 실제 댓글 분류 테스트
- ☐ 5. UI 수정
- ☐ 6. 서비스 배포
- ☐ 7. 초기 사용자 모집 및 마케팅